

目录

- I. 对角式双舵轮 AGV 动力学与运动学模型总结。 2
 - A. 运动学模型..... 3
 - B. 刚体动力学模型..... 3
 - 1) 纵向运动学..... 3
 - 2) 侧向动力学与侧偏角 3
 - 3) 横摆动力学..... 3
 - C. 轮胎模型 4
- II. 底层运动控制..... 4
 - A. 偏航运动控制 4
 - B. 稳定性增强策略 4
 - 1) 虚拟测偏阻尼..... 5
 - 2) 虚拟横摆阻尼..... 5
 - C. 牵引力控制..... 5
 - D. 低速与静止处理..... 5
- III. 控制算法 6
 - A. 还没想好[公式节 \(下一节\)](#)..... 6
 - B. 自适应模型预测控制算法 7
 - 1) LPV 预测模型与测量扰动通道 8
 - 2) 滚动时域优化问题..... 9
 - 3) 在线自适应更新机制 10
 - C. GRU 算法..... 11
 - D. 使用贝叶斯优化进行控制器调参 **(可以考虑在此处进行创新)** 12
- IV. 结果及讨论..... 13
 - A. GRU 学习和优化结果[公式章 \(下一章\) 节 1公式章 \(下一章\) 节 4](#)..... 14

I. 对角式双舵轮 AGV 动力学与运动学模型总结。

首先是理想运行环境和基本假设：1.假设 AGV 车体为绝对刚体，在重载或高动态行驶过程中不发生弹性形变；2.假设车辆主要在二维平面内运动，忽略垂直方向的跳动、俯仰和侧倾的动态惯性效应；3.假设轮胎始终垂直于地面，忽略车轮外倾角及其产生的侧向推力；4.假设货物与车体相对固定，无晃动或是相对位移；5.非均一地面和变摩擦特性。




图 1：对角式双舵轮 AGV 简化示意图

参数	符号(单位)
车体质心的线速度	v
航向角	ψ
质心侧偏角	β
转弯半径	R
轴距、轮距	$L、W$
左前轮、右后轮转向角	$\delta_{lf}、\delta_{rr}$
横摆角速度	ω
大地坐标系	XOY
车体坐标系	xoy

过渡段

A. 运动学模型

在车体坐标系 xoy 下，车辆质心的速度矢量为：

$$\vec{v} = [v \cos \beta, v \sin \beta]^T \quad (6.1)$$

在大地坐标系 XOY 下，位置更新方程为：

$$\begin{cases} \dot{X} = v \cos(\psi + \beta) \\ \dot{Y} = v \sin(\psi + \beta) \\ \dot{\psi} = \omega \end{cases} \quad (6.2)$$

B. 刚体动力学模型

基于牛顿-欧拉方程，考虑 3-DOF 平面运动（纵向、横向、横摆）

1) 纵向运动学

沿车体 x 轴的力平衡方程：

$$m_{eff} a = \text{sum}(F_x) - F_{drag} - F_{slope} \quad (6.3)$$

其中：

$$\text{总驱动力： } \text{sum}(F_x) = F_{x,lf} + F_{x,rr}$$

$$\text{总阻力： } F_{drag} = F_{roll} + F_{aero}$$

$$F_{roll} = C_r mg \cos(\theta_{slope})$$

$$F_{aero} = 0.5 \rho C_d A v^2 \text{sign}(v)$$

$$\text{有效质量： } m_{eff} = m + 2(I_w + I_m n^2) / r^2$$

2) 侧向动力学与侧偏角

沿车体 y 轴的力平衡：

$$\text{sum}(F_y) = mv(\dot{\beta} + \omega) \quad (6.4)$$

整理得到侧偏角变化率 $\dot{\beta}$ ：

$$\dot{\beta} = (F_{y,lf} + F_{y,rr}) / mv - \omega \quad (6.5)$$

公式(6.5)在 $v \rightarrow 0$ 时存在奇异性，物理上对应静止时侧偏角无意义。

3) 横摆动力学

绕质心 z 轴的力矩平衡方程：

$$I_z \dot{\omega} = \text{sum}(M_z) \quad (6.6)$$

总力矩由两部分组成：

轮胎侧向力产生的力矩： $M_{z,\text{tire}} = \frac{L}{2}(F_{y,\text{lf}} - F_{y,\text{rr}})$ ，此处假设转向角较小，侧向力主要贡献于横摆；

差动驱动产生的力矩： $M_{z,\text{drive}} = \frac{W}{2}(F_{x,\text{lf}} - F_{x,\text{rr}})$

C. 轮胎模型

采用线性化轮胎模型结合摩擦圆限制。

轮胎侧偏角：

$$\begin{cases} \alpha_{\text{lf}} = \beta + \frac{\frac{L}{2}\omega}{v} - \delta_{\text{lf}} \\ \alpha_{\text{rr}} = \beta - \frac{\frac{L}{2}\omega}{v} - \delta_{\text{rr}} \end{cases} \quad (6.7)$$

侧向力：

$$F_{y,\text{lin}} = -C_\alpha \alpha \quad (6.8)$$

考虑到附着极限 μN ，实际侧向力为：

$$F_y = \text{sign}(F_{y,\text{lin}}) \min(|F_{y,\text{lin}}|, \mu N) \quad (6.9)$$

底层部分的控制策略可以短一些，不用写这么长。底层运动控制部分也是一样。

II. 底层运动控制

A. 偏航运动控制

物理模型表明差动驱动力矩 $M_{z,\text{drive}}$ 取决于 $F_{x,\text{lf}}$ 和 $F_{x,\text{rr}}$ 的差值。模型中内置了一个 P 控制器来主动调节这个差值。

控制目标：使实际横摆角速度 ω 跟踪指令 ω_{cmd} 。

控制率：

1. 计算误差： $e_\omega = \omega_{\text{cmd}} - \omega$
2. 比例控制计算期望角加速度： $\dot{\omega}_{\text{des}} = K_p e_\omega$
3. 计算所需额外力矩： $M_{z,\text{req}} = I_z \dot{\omega}_{\text{des}}$
4. 转换为驱动力差指令： $\delta_{F,x} = \frac{M_{z,\text{req}}}{W}$

实现效果：这使得 AGV 表现为一个对横摆角速度指令闭环的系统，而非开环系统。

B. 稳定性增强策略

为了解决刚体模型在低速下的数值奇异性以及增强动态稳定性，模型引入了虚拟阻尼项。

1) 虚拟侧偏阻尼

在 $\dot{\beta}$ 方程中认为增加了强阻尼项：

$$\dot{\beta}_{model} = \frac{sum(F_y)}{mv} - \omega - 5\beta \quad (6.10)$$

物理意义：这是一项并不存在的物理力，但在控制上等效于通过微调转向或驱动力来施加一个“使其回到运动方向”的恢复力矩。

作用：防止侧偏角 β 在仿真中发散，特别是在低速段，强制 β 收敛到 0，模拟了轮胎低速下的强自对准特性。

2) 虚拟横摆阻尼

在横摆动力学中添加了与 ω 成正比的阻尼力矩：

$$M_{z, total} = M_{z, phys} - C_{yaw}\omega \quad (6.11)$$

作用：增加系统的阻尼比，减少超调和震荡，模拟车身摩擦或未建模的阻尼效应。

C. 牵引力控制

模型中内嵌了基于摩擦椭圆的牵引力限制器：

$$F_{x, allow} = \mu N \sqrt{1 - \frac{F_y^2}{(\mu N)^2}} \quad (6.12)$$

策略：当检测到侧向力 F_y 较大（如急转弯）时，主动限制纵向驱动力 F_x 的上限。

作用：防止“顾此失彼”，确保轮胎合力不超出附着极限圆，有限保证侧向稳定性，其次提供纵向驱动力。

D. 低速与静止处理

当 $v < v_{thresh}$ 时：

- 1) 运动学：使用显式的强阻尼 $\dot{\beta} = -C_{low}\beta$ 强制侧偏角归零。
- 2) 动力学：禁止差动偏航控制，防止在原地产生过大的自旋力矩导致数值不稳定。
- 3) 阻力：滚动阻力计算考虑了符号函数平滑，避免零速震荡。

该 AGV 模型是一个面向控制的增强型动力学模型。

物理层：通过牛顿-欧拉方程和非线性轮胎模型，准确描述了车辆的基本物理特性（惯性、摩擦、几何约束）。


控制层：内嵌了差动偏航控制、虚拟阻尼稳定和牵引力保护，使得该模型不仅反映了“车是什么”，还反映了“底层驱动器怎么控制车”。

这种设计非常适合用于上层算法（如路径规划、轨迹跟踪 MPC）的开发与验证，因为它屏蔽了底层电机控制的复杂性，提供了一个稳定、响应可预测的被控对象接口。

III. 控制算法

A. 还没想好

在路径跟踪任务中，控制目标是将车辆当前的运动状态收敛至参考路径上。在图 2 中，车辆在全局坐标系下的状态被转换为路径坐标系下的跟踪误差。其中 (X, Y) 是车辆重心在全局坐标系下的位置； ψ 是车辆当前的航向角； v 是车辆当前的纵向速度； ω 是车辆当前的横摆角速度。 (X_r, Y_r) 是参考路径上正交投影点的坐标； ψ_r 是参考点的切向航向角； κ_r 是参考点的路径曲率； v_{ref} 是参考速度。



车辆与参考点在全局坐标系下的位置偏差：

$$\begin{cases} e_x = X - X_r \\ e_y = Y - Y_r \end{cases} \quad (7.1)$$

为了得到相对于路径的横向误差，需要将全局位置偏差投影到参考路径的法线方向上。根据旋转变换矩阵：

$$\begin{bmatrix} e_x^{path} \\ e_y^{path} \end{bmatrix} = \begin{bmatrix} \cos \psi_r & \sin \psi_r \\ -\sin \psi_r & \cos \psi_r \end{bmatrix} \begin{bmatrix} e_x \\ e_y \end{bmatrix} \quad (7.2)$$

其中 e_x^{path} 代表车辆位置相对于参考点的纵向距离。由于我们将参考点 (X_r, Y_r) 定义为车辆在路径上的正交投影点，根据正交投影的几何性质，车辆与该点的连线向量必然垂直于该点的切向向量。因此，纵向误差 e_x^{path} 在理论上恒为零，故而在后续控制模型中将其忽略，仅保留横向误差：

$$e_y = -\sin(\psi_r)(X - X_r) + \cos(\psi_r)(Y - Y_r) \quad (7.3)$$

航向误差定义为车辆当前航向与参考路径切向的偏差。为了消除角度周期性的影响，计算结果需归一化至主值区间：

$$e_\psi = \psi - \psi_r, e_\psi \in (-\pi, \pi] \quad (7.4)$$

纵向速度跟踪误差直接定义为：

$$e_v = v - v_{ref} \quad (7.5)$$

为了提高曲线跟踪性能，引入基于路径曲率的前馈项。参考横摆角速度 ω_{ref} 由参考速度和路径曲率由运动学关系决定：

$$\omega_{ref} = v_{ref} \cdot \kappa_r \quad (7.6)$$

角速度误差则定义为测量值与参考值的偏差：

$$e_\omega = \omega - \omega_{ref} \quad (7.7)$$

根据上述对误差变量的分析，可以确定对 AGV 行驶的控制任务在物理上可解耦为纵向动力和横向运动两个维度的调节。具体而言，速度误差 e_v 的消除主要依赖于纵向驱动/制动力的调节，而横向位置误差 e_y 与航向误差 e_ψ 的修正则需通过精确控制车辆的转向角速度来实现。

B. 自适应模型预测控制算法

传统线性模型预测控制在工业应用中广泛成功，其优势在于：可显式处理约束、通过滚动优化预测未来行为，且在线求解通常可转化为二次规划以获得较高计算效率。但传统线性 MPC 往往基于单一工作点的线性时不变模型，性能对模型失配较为敏感。

对于自动驾驶 AGV，动力学在变曲率弯道、变坡度以及载荷/摩擦变化时呈现明显非线性与时变特性，固定 LTI 模型难以覆盖全工况。一个直接的改进途径是非线性 MPC (NMPC)，即在预测域内直接采用非线性模型进行滚动优化，从而在更大工况范围内保持较高模型一致性；但 NMPC 通常需要在线求解非线性规划问题，计算开销更高，且可能对初值、模型精度与实时算力更敏感。

本文采用折中且工程可实现的方案：基于线性变参数 (LPV) 框架构建自适应 MPC。其核心思想是引入调度变量 ρ_k ，在每个采样时刻根据实时运行工况对预测模型（以及权重/约束）进行在线更新，使系统在保持线性 MPC 求解效率与约束处理便利性的同时，获得对工况漂移的自适应能力。

为在多工况下实现一致的闭环跟踪性能，本研究构建了基于 LPV 框架的自适应模型预测控制器。其核心思想是引入调度变量 ρ_k ，在每个采样时刻对预测模型与控制权重进行在线更新，从而以线性模型簇近似描述原系统在当前工作区间内的局部动力学。**（后面可以补一个对约束进行在线更新的功能）**

1) LPV 预测模型与测量扰动通道

控制器的离散时间预测模型采用误差状态空间形式。定义路径坐标系下的误差状态向量为：

$$x_k = [e_y, e_\psi, e_v, e_\omega]^\top, \quad (7.8)$$

测量扰动为坡度角的在线估计值： $d_k = \theta_k$

在采样时刻 k ，预测模型写为：

$$\begin{cases} x_{k+1} = A(\rho_k)x_k + B(\rho_k)u_k + E(\rho_k)d_k \\ y_k = C(\rho_k)x_k \end{cases} \quad (7.9)$$

其中， $u_k = [F_{cmd,k}, \omega_{cmd,k}]^\top$ ，包含纵向指令力 F_{cmd} （单位：N）与指令转向角速度 ω_{cmd} （单位：rad/s）。 y_k 为 MPC 的测量输出，本文假设所有误差状态均可由观测器或传感器获得，故选取输出矩阵 $C(\rho_k)$ 为单位矩阵，即 y_k 等同于状态向量 x_k 。（这个部分交代一下输入变量、控制变量等信息） 已改完

调度变量选取为 $\rho_k = [v_k, \omega_k, \theta_k]^\top$ ，其中 v_k 与 ω_k 来自车辆状态/参考量， θ_k 可由上层 Mamba 模块提供在线估计 $\hat{\theta}_k$ 。为抑制调度跳变带来的数值不稳定性，本文对 ρ_k 采用一阶低通滤波得到 ρ_k^f ，并以 ρ_k^f 作为模型更新的实际调度输入。

具体实现中，矩阵 $A(\rho), B(\rho), E(\rho)$ 来自三维网格线性化数据库，并通过三线性插值计算。其等价形式可表示为 8 个网格顶点的凸组合：

$$\begin{cases} A(\rho) = \sum_{j=1}^8 w_j(\rho) A_j \\ B(\rho) = \sum_{j=1}^8 w_j(\rho) B_j \\ E(\rho) = \sum_{j=1}^8 w_j(\rho) E_j, \end{cases} \quad (7.10)$$

其中 $w_j(\rho) \geq 0$ 且 $\sum_j w_j(\rho) = 1$ 。

对于路径坐标系误差模型，离散状态空间矩阵具有如下结构：

$$\mathbf{A}(\rho) = \begin{bmatrix} 1 & A_{12} & 0 & 0 \\ 0 & 1 & 0 & A_{24} \\ 0 & 0 & A_{33} & 0 \\ 0 & 0 & 0 & A_{44} \end{bmatrix} \quad (7.11)$$

$$\mathbf{B}(\rho) = \begin{bmatrix} 0 & 0 \\ 0 & 0 \\ B_{31} & 0 \\ 0 & B_{42} \end{bmatrix} \quad (7.12)$$

$$\mathbf{C} = \mathbf{I}_4 \quad (7.13)$$

$$\mathbf{E}(\rho) = \begin{bmatrix} 0 \\ 0 \\ E_3 \\ 0 \end{bmatrix} \quad (7.14)$$

其中各参数为：

$$A_{12} = v \cdot T_s, A_{24} = T_s, A_{33} = 1 - \frac{C_r g + \rho C_d A v}{m_{eff}} T_s, A_{44} = 1 - \frac{C_{yaw}}{I_z} T_s,$$

$$B_{31} = \frac{T_s}{m_{eff}}, B_{42} = \frac{K_\omega T_s}{I_z}, E_3 = -\frac{g \cdot T_s}{m_{eff}}, \text{ 其中 } C_{yaw} \text{ 为横摆阻尼系数, } K_\omega \text{ 为底层角速度控}$$

制器的比例增益。

注：

2) 滚动时域优化问题

在每个采样时刻 k ，控制器求解有限预测域内的滚动优化问题。设预测步长为 N_p 、控制

步长为 N_c ，以控制增量序列 $\Delta U_k = \{\Delta u_{k|k}, \Delta u_{k+1|k}, \dots, \Delta u_{k+N_c-1|k}\}$ 为决策变量，最小化如下二

次型代价：

$$\begin{aligned} \min_{\Delta U_k} J_k = & \sum_{i=1}^{N_p} (y_{k+i|k} - r_{k+i|k})^T Q(\rho_k^f) (y_{k+i|k} - r_{k+i|k}) + \sum_{i=0}^{N_c-1} u_{k+i|k}^T R(\rho_k^f) u_{k+i|k} \\ & + \sum_{i=0}^{N_c-1} (\Delta u_{k+i|k})^T dR(\rho_k^f) (\Delta u_{k+i|k}) + \sum_{i=1}^{N_p} e_{slack,k+i|k}^T W_{slack} e_{slack,k+i|k}. \end{aligned} \quad (7.15)$$

1.在代价函数中加入和坡度相关的约束项。

2.加上规避障碍的功能(先静态，再动态)，可以参考丁文章中的避障方法。

在这部分说明坡度角对车辆的影响，强调重要性。

其中 $Q(\rho)$ 、 $R(\rho)$ 、 $dR(\rho)$ 分别对应输出误差、操纵变量及操纵变量变化率的权重。本研究在误差坐标系下采用 $r_{k+i|k} = 0$ 作为参考，从而直接驱动误差收敛。为提高可行性，本文对关键输出误差（如 e_y 、 e_ψ ）采用软约束，并通过松弛变量 e_{slack} 引入额外惩罚项；其权重 W_{slack} 对应实现中的软约束惩罚系数（MinECR/MaxECR）。

约束条件包括操纵变量幅值与变化率约束，以及输出误差约束：

$$\begin{cases} x_{k+i+1|k} = A(\rho_k^f)x_{k+i|k} + B(\rho_k^f)u_{k+i|k} + E(\rho_k^f)d_{k+i|k} \\ u_{\min}(\rho_k^f) \leq u_{k+i|k} \leq u_{\max}(\rho_k^f) \\ \Delta u_{\min}(\rho_k^f) \leq \Delta u_{k+i|k} \leq \Delta u_{\max}(\rho_k^f) \end{cases} \quad (7.16)$$

并对关键输出误差设置软约束以提高可行性。扰动项 $d_{k+i|k}$ 在实现中使用当前测量扰动输入并在预测域内采用冻结近似。在 MPC 控制器介绍的结尾部分对"把坡度角作为扰动"进行叙述。包括：为什么引入坡度角，对车辆有哪些影响，当前 MPC 中为什么用这种方式添加坡度角，实现的效果等等。

3) 在线自适应更新机制

本文的自适应机制在每个采样时刻执行如下步骤：

- 由车辆状态/参考量与环境估计构造并滤波调度变量 $\rho_k^f = [v_k, \omega_k, \theta_k]^\top$ ；
- 由 LPV 数据库对 A, B, C, E 做三线性插值，得到当前时刻预测模型；
- 根据 ρ_k^f 对权重 Q, R, dR 以及输入约束上下界进行在线调度；
- 将上述更新后的模型与参数输入 MPC 求解器，计算当前最优控制量 u_k 并施加至被控对象。

通过以上机制，控制器能够在模型层与优化层同时反映当前工况变化，从而提升系统在转弯与坡度扰动等复杂工况下的跟踪性能与鲁棒性。

C. GRU 算法

加：1.为什么引入坡度判断。2.传统 IUM 为什么不行。3.IMU 不行的前提下，使用那些输入，及其理由。4.为什么使用 GRU 算法，以及为什么 GRU 比起其他控制策略要好，尤其是 RNN，要对比着讲(其他的不确定因素)。(IMU 过程中可以引入其他论文)

在 AGV 的坡道与转弯工况下，车辆纵向动力学会受到坡度角 θ 的显著影响，使得误差模型中的扰动项 $d_k = \theta_k$ 以及调度变量 $\rho_k = [v_k, \omega_k, \theta_k]^T$ 随工况快速变化。如果仅依赖固定阈值或简单几何关系从 IMU 直接反推出坡度，往往会受到非重力加速度、轮胎振动以及噪声漂移的干扰，导致 θ 估计抖动并进一步引起 LPV 插值与权重/约束调度不稳定。为此，本文在控制器上层引入 GRU (Gated Recurrent Unit) 作为序列特征提取器，利用车辆可测输出构造时间序列输入 x_t ，在线输出坡度角估计 $\hat{\theta}$ 并注入 MPC 的测量扰动通道 (MD)，从而实现更平滑且抗噪的坡度感知。其中车辆输出主要包含 IMU 加速度/角速度、轮速、舵角、电机电流与速度差分等信息。


选择 GRU 的原因在于其在保持时序建模能力的同时具备更低的参数规模与推理开销，更适合实时控制回路集成。相比基于 IMU 的传统坡度估计，GRU 能在存在机体纵向加减速、路面扰动和传感器偏置时，利用多源量测的时序一致性学习“坡度—动力响应—量测特征”的隐式映射，从而降低由非重力加速度引起的系统性误差。相比 LSTM，GRU 采用更简化的门控结构，在相近精度下通常具有更快的收敛速度与更低的计算/存储占用。其核心状态更新可写为：

$$\begin{cases} r_t = \sigma(W_r x_t + U_r h_{t-1} + b_r) \\ z_t = \sigma(W_z x_t + U_z h_{t-1} + b_z) \\ \tilde{h}_t = \tanh(W_h x_t + U_h (r_t \odot h_{t-1}) + b_h) \\ h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \end{cases} \quad (7.17)$$

其中 r_t 为重置门， z_t 为更新门， $\tilde{h}_t$ 为候选隐状态， h_t 为时刻 t 的隐状态。 x_t 表示输入特征向量， W_r, W_z, W_h 与 U_r, U_z, U_h 为可训练权重矩阵， b_r, b_z, b_h 为偏置项； $\sigma(\cdot)$ 与 $\tanh(\cdot)$ 分别为 Sigmoid 与双曲正切非线性函数， $\odot$ 表示按元素乘。

为同时提升状态识别的鲁棒性与坡度估计精度，本文采用多任务输出头：主工况分类（如 flat/stall/slope）、转弯分类以及坡度回归（ $\hat{\theta}$ ），其输出形式为：

$$\begin{cases} p_t^{main} = \text{softmax}(W_{main}h_t + b_{main}), \\ p_t^{turn} = \text{softmax}(W_{turn}h_t + b_{turn}), \\ \hat{\theta}_t = W_{\theta}h_t + b_{\theta}. \end{cases} \quad (7.18)$$



D. 使用贝叶斯优化进行控制器调参（可以考虑在此处进行创新）可以放在仿真里说。

LPV-MPC 控制器涉及权重矩阵、约束边界、调度滤波以及工况自适应阈值等多类超参数，且参数之间存在显著耦合。若采用手动调参，不仅需要大量闭环仿真迭代、时间成本高，而且高度依赖控制工程经验；在多场景（转弯、颠簸、坡道、直线等）共同约束下，手动方法往往只能获得次优折中解。为此，本文采用贝叶斯优化将闭环评估过程视为黑盒目标函数，通过最小化综合代价 $J(\phi)$ 自动搜索控制器参数向量 ϕ ，实现可复现、可扩展的自动化调参。

贝叶斯优化适用于“单次评估代价高、无解析梯度且目标可能非凸”的超参数搜索问题。本文将调参建模为两层优化结构：内层在给定 ϕ 时执行闭环仿真并计算代价 $J(\phi)$ ；外层通过代理模型与采集函数选择下一组参数进行评估。其形式可写为：

$$\begin{cases} \phi^* = \arg \min_{\phi \in \Phi} f(\phi) \\ f(\phi) = J(\phi) = \sum_{s \in \mathcal{S}} w_s J_s(\phi) \end{cases} \quad (7.19)$$

其中 ϕ^* 表示使目标函数达到最小的最优参数向量。 $\mathcal{S}$ 为场景集合， w_s 为场景权重。为体现 $J_s(\phi)$ 与闭环性能指标的“具体关系”，本文在实现中将 $J_s(\phi)$ 构造为若干可计算指标的加权组合，例如：

$$\begin{aligned} J_s(\phi) = & \lambda_y \text{RMSE}(e_y) + \lambda_{\psi} \text{RMSE}(e_{\psi}) + \lambda_v \text{RMSE}(e_v) \\ & + \lambda_{\omega} \text{RMSE}(e_{\omega}) + \lambda_{\Delta u} \text{RMSE}(\Delta u) + \lambda_{\text{vio}} \Pi_{\text{vio}} + \lambda_T \bar{T}_{\text{solve}} \end{aligned} \quad (7.20)$$

其中 Π_{vio} 表示约束违反惩罚项, $\bar{T}_{\text{solve}}$ 表示平均求解耗时。外层 BO 在第 n 次迭代基于历史观测数据 $\mathcal{D}_n = \{(\phi_i, f(\phi_i))\}_{i=1}^n$ 拟合代理模型并通过采集函数 $a(\phi; \mathcal{D}_n)$ 权衡探索与利用, 选择下一次评估点:

$$\phi_{n+1} = \arg \max_{\phi \in \Phi} a(\phi; \mathcal{D}_n). \quad (7.21)$$

本文实现中采用两阶段流程: 第一阶段进行全局搜索获得较优解; 第二阶段以第一阶段优点为中心收缩边界进行局部精细搜索, 以提升收敛质量并降低遗漏较优解的风险。

BO 实际调优的参数向量 ϕ 主要包括: 输出误差权重基值 $q_y, q_\psi, q_v, q_\omega$; 操纵量权重 r_F, r_ω 与增量权重 dr_F, dr_ω ; 权重随工况变化的形状参数 $\alpha_Q, \beta_Q, \alpha_R, \beta_R, \alpha_{dR}, \beta_{dR}$; 输入/增量约束的缩放系数 $scale_umin, scale_umax$ (含 lo/hi 区间缩放); 调度量滤波时间常数 τ ; 以及场景自适应参数。优化完成后生成最优参数映射并用于后续闭环验证。

IV. 结果及讨论

本文的仿真实验均在 Simulink 闭环平台中完成, 其中被控对象采用高保真非线性 AGV 动力学模型。该模型在纵向/横向/横摆耦合的刚体动力学基础上, 考虑了轮胎力饱和与附着限制、滚动阻力与空气阻力、坡度重力分量、驱动与转向执行器动态等关键非线性因素, 从而能够在直线、转弯、颠簸与坡道等多类场景下提供更接近真实工况的闭环评估。表 1 列出了所有模型参数。

Parameter	Value	Parameter	Value
m	100.0 (kg)	μ	0.8
L	2.0(m)	ρ	1.225(kg m ³)
W	0.8(m)	$C_d A$	0.5(m ²)
I_z	16.67(kg m ²)	g	9.81(m/s ²)
h_{cg}	0.5	T_s	0.05s
r	0.15(m)	N_p	30
C_r	0.015	N_c	10

表 1 MPC 和 AGV 模型参数

A. GRU 学习和优化结果

本节首先给出 GRU 的学习结果与泛化表现，并进一步结合在线推理环节中的“延迟敏感参数”说明其工程化优化要点。GRU 采用“主工况分类 + 转弯状态分类 + 坡度角回归”的多任务输出结构，以序列输入刻画 AGV 在坡道/转弯工况下的动力学特征。网络输入由闭环平台可测的 19 维原始观测通道及其派生量构成；网络为两层 GRU，包含由 16 个神经元以及两个分别包含 96 个隐藏神经元的隐藏层，并设置 dropout = 0.2。该模型共有三个独立的输出头，主分类头用于识别地形状态（Flat/Stall/Slope），包含三个神经元；转弯分类头用于识别转向状态（Right/Straight/Left），包含三个神经元；坡度回归头用于估计坡度角 θ ，由一个神经元组成。（这部分的内容介绍应该挪到控制算法的部分，只需要添加仿真结果就可以了）

为保证训练数据的可复现性与可追溯性，本文所用 GRU 数据集由“仿真生成—预处理切片”两阶段流程得到。第一阶段在 Simulink 闭环仿真环境下批量生成多场景（直线、左右转、坡道、颠簸）时序数据各 200 次；通过对参考路径与初始条件进行随机化（初速度、转弯半径、坡度角范围等），并在其中 70% 的回合引入传感器噪声注入，同时可随机注入牵引效率退化、外载荷突变等外部扰动以提升分布覆盖，从而获得包含不同工况切换与扰动强度的样本。第二阶段对原始观测提取“仅由可测原始量与简单派生量构成”的 19 维特征，并采用滑窗形成序列样本：在每个回合内部按固定步幅递推截取长度为 48 的子序列（步幅 12，因此相邻样本存在重叠），且仅保留完整窗口而不进行零填充；监督信号采用“窗口末端对齐”的定义，即主工况/转弯标签与坡度真值均取窗口最后一个采样时刻的标注值，从而使每个样本可解释为“利用过去约 2.4 s 的测量预测当前时刻的工况与坡度”。数据划分按回合分组以降低跨回合泄漏风险，并按 0.70/0.15/0.15 的比例划分训练集/验证集/测试集（72615/15031/15054）；归一化采用 z-score 且仅使用训练集统计量。

在训练设置方面，本文采用基于自定义训练循环的 Adam 优化器，初始学习率设为 1×10^{-3} ，并使用余弦退火进行学习率衰减：

$$\eta(e) = \eta_0 \cdot \frac{1}{2} \left(1 + \cos \left(\pi \frac{e}{E_{\max}} \right) \right) \quad (4.1)$$

其中 e 为当前 epoch， $E_{\max} = 200$ 为最大训练轮次，批量大小为 64。训练过程中采用全局范数梯度裁剪（阈值 5.0）以抑制梯度爆炸，并基于验证集总损失实施早停：当验证损失在连续 20 个 epoch 内未能超过 10^{-4} 的改善幅度时终止训练，并回退到验证损失最优时刻的模型参数。

离线测试集上，主工况分类准确率达到 99.03%、转弯分类准确率 99.26%；坡度角回归在测试集上的 MAE 约为 1.08° 。为验证在线可用性，本文在 60 段不同种类在线场景中进行推理评估。在线主工况识别平均准确率为 96.77%；在包含坡度变化的 20 段场景中，坡度估计 MAE 平均约 0.86° 。进一步在闭环仿真评估中，速度跟踪误差的均方根（RMS）均值为 0.0303，坡度估计 MAE 均值约 0.31° ，说明在闭环条件下坡度估计可获得更稳定的统计表现。